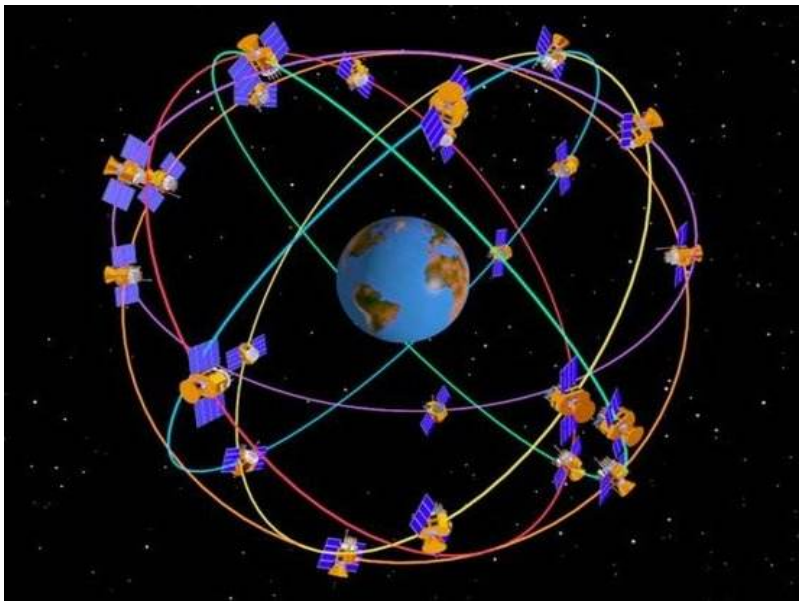
第四章 求解优化问题和非线性方程组的迭代法

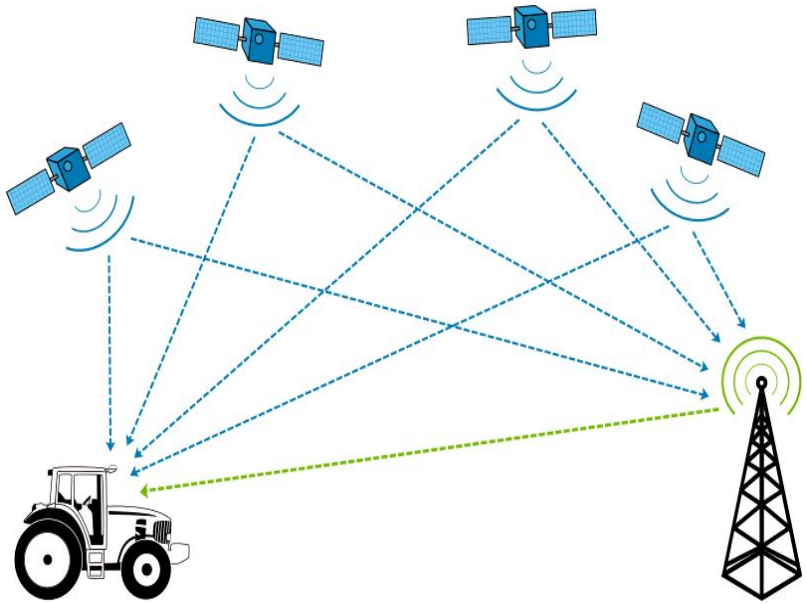
殷东生
yindongsheng@tsinghua.edu.cn

清华大学数学基础教学中心

2026年秋季学期

GPS定位





每个卫星会有位置和距离数据 $\boldsymbol{s}_i = (x_i, y_i, z_i, \rho_i)^\intercal$，定位的位置和距离为 $\boldsymbol{u} = (x, y, z, b)^\intercal$，则可得非线性方程组：

$$\sqrt{(x_i - x)^2 + (y_i - y)^2 + (z_i - z^2)} + b = \rho_i, \quad i = 1, 2, 3, 4$$

最优化问题

优化问题

- 最优化问题（也称优化问题）泛指定量决策问题，主要关心如何对有限资源进行有效分配和控制，并达到某种意义上的最优。
- 通常需要对问题的需求进行定性和定量分析，建立恰当的数学模型，并设计合适的计算方法来寻找问题的最优解，探索研究模型和算法的理论性质，找到合适的算法并考察算法的计算性能等。

计算机的高速发展为最优化方法提供了有力辅助工具；最优化方法被广泛应用于科学与工程计算、金融与经济、管理科学、工业生产、图像与信号处理、数据分析与人工智能、计算物理与化学等众多领域。计算、优化和统计是机器学习的三个支柱之一。

优化问题的定义

优化问题通常可描述为

$$\begin{aligned} \min \quad & f(\boldsymbol{x}), \\ s.t \quad & \boldsymbol{x} \in \mathcal{X}, \end{aligned}$$

$\boldsymbol{x} \in \mathbb{R}^n$ 为决策变量，$f : \mathbb{R}^n \to \mathbb{R}$ 是目标函数，$\mathcal{X} \subset \mathbb{R}^n$ 是约束集合或可行域，可行域包含的点称为可行解或可行点。若 $\mathcal{X} = \mathbb{R}^n$，则称为无约束优化问题。

$\mathcal{X}$ 通常可由约束函数 $g_i(\boldsymbol{x}) : \mathbb{R}^n \to \mathbb{R}, 1 \le i \le k$ 和 $h_j(\boldsymbol{x}) : \mathbb{R}^n \to \mathbb{R}, 1 \le j \le l$ 如下定义：

$$\mathcal{X} = \left\{ \boldsymbol{x} \in \mathbb{R}^n \middle| g_i(\boldsymbol{x}) \le 0, h_j(\boldsymbol{x}) = 0 \right\}_{i,j}.$$

在所有满足约束条件的决策变量中，使目标函数取最小值的变量 $\boldsymbol{x}^*$ 称为优化问题的最优解，即对任意 $\boldsymbol{x} \in \mathcal{X}$ 都有 $f(\boldsymbol{x}) \ge f(\boldsymbol{x}^*)$。

最优解

1. 点 $\boldsymbol{x}^*$ 称为全局极小点若

$$f(\boldsymbol{x}^*) \leq f(\boldsymbol{x}),\ \forall \boldsymbol{x} \in \mathcal{X}.$$

也称为极小值点或（全局）最优解。

2. 点 $\boldsymbol{x}^*$ 称为局部极小点若存在 $\boldsymbol{x}^*$ 的一个 ϵ 邻域 $N_\epsilon(\boldsymbol{x}^*)$ 使得

$$f(\boldsymbol{x}^*) \leq f(\boldsymbol{x}),\ \forall \boldsymbol{x} \in N_\epsilon(\boldsymbol{x}^*) \bigcap \mathcal{X}.$$

也称为局部最优解。

3. 进一步如有

$$f(\boldsymbol{x}^*) < f(\boldsymbol{x}),\ \forall \boldsymbol{x} \in N_\epsilon(\boldsymbol{x}^*) \bigcap \mathcal{X}, \boldsymbol{x}^* \neq \boldsymbol{x}.$$

则称 $\boldsymbol{x}^*$ 为严格局部极小解（点）。

定义（梯度）

给定函数 $f:\mathbb{R}^n \to \mathbb{R}$，且 f 在点 $\boldsymbol{x}$ 的一个邻域内有意义，若存在向量 $\boldsymbol{g} \in \mathbb{R}^n$ 满足

$$\lim_{\boldsymbol{p}\to\boldsymbol{0}} \frac{f(\boldsymbol{x}+\boldsymbol{p}) - f(\boldsymbol{x}) - \boldsymbol{g}^{\mathsf{T}}\boldsymbol{p}}{\|\boldsymbol{p}\|} = 0,$$

其中 $\|\cdot\|$ 是任意的向量范数，就称 f 在点 $\boldsymbol{x}$ 处可微。此时 $\boldsymbol{g}$ 称为 f 在点 $\boldsymbol{x}$ 处的梯度，记作 $\nabla f(\boldsymbol{x})$。如果对区域 D 上的每一个点 $\boldsymbol{x}$ 都有 $\nabla f(\boldsymbol{x})$ 存在，则称 f 在 D 上可微。

若 f 在点 $\boldsymbol{x}$ 处的梯度存在，令 $\boldsymbol{p} = \epsilon \boldsymbol{e}_i$，$\boldsymbol{e}_i$ 是第 i 个分量为 1 的单位向量，可知 $\nabla f(\boldsymbol{x})$ 的第 i 个分量为 $\dfrac{\partial f(\boldsymbol{x})}{\partial x_i}$，则

$$\nabla f(\boldsymbol{x}) = \left[\frac{\partial f(\boldsymbol{x})}{\partial x_1}, \frac{\partial f(\boldsymbol{x})}{\partial x_2}, \cdots, \frac{\partial f(\boldsymbol{x})}{\partial x_n}\right]^{\mathsf{T}}.$$

定义（海瑟矩阵）

如果函数 $f(\boldsymbol{x}) : \mathbb{R}^n \to \mathbb{R}$ 在点 $\boldsymbol{x}$ 处的二阶偏导数

$$\frac{\partial^2 f(\boldsymbol{x})}{\partial x_i \partial x_j}, \quad i, j = 1, 2, \ldots, n$$

都存在，则

$$\nabla^2 f(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial^2 f(\boldsymbol{x})}{\partial x_1^2} & \frac{\partial^2 f(\boldsymbol{x})}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(\boldsymbol{x})}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\boldsymbol{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\boldsymbol{x})}{\partial x_2^2} & \cdots & \frac{\partial^2 f(\boldsymbol{x})}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\boldsymbol{x})}{\partial x_n \partial x_1} & \frac{\partial^2 f(\boldsymbol{x})}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(\boldsymbol{x})}{\partial x_n^2} \end{bmatrix} \in \mathbb{R}^{n \times n}$$

称为 f 在点 $\boldsymbol{x}$ 处的海瑟矩阵（Hessian）。

当 $\nabla^2 f(\boldsymbol{x})$ 在区域 D 上的每个点 $\boldsymbol{x}$ 处都存在时，称 f 在 D 上二阶可微。若 $\nabla^2 f(\boldsymbol{x})$ 在 D 上还连续，则称 f 在 D 上二阶连续可微，可以证明此时海瑟矩阵是一个对称矩阵。

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$$

定义（雅可比矩阵）

当 $f : \mathbb{R}^n \to \mathbb{R}^m$ 是向量值函数时，可定义它的雅可比（Jacobi）矩阵 $\boldsymbol{J}(x) \in \mathbb{R}^{m\times n}$，它的第 i 行是分量 $f_i(\boldsymbol{x})$ 梯度的转置，即

$$\boldsymbol{J}(x) = \begin{bmatrix} \frac{\partial f_1(\boldsymbol{x})}{\partial x_1} & \frac{\partial f_1(\boldsymbol{x})}{\partial x_2} & \cdots & \frac{\partial f_1(\boldsymbol{x})}{\partial x_n} \\ \frac{\partial f_2(\boldsymbol{x})}{\partial x_1} & \frac{\partial f_2(\boldsymbol{x})}{\partial x_2} & \cdots & \frac{\partial f_2(\boldsymbol{x})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m(\boldsymbol{x})}{\partial x_1} & \frac{\partial f_m(\boldsymbol{x})}{\partial x_2} & \cdots & \frac{\partial f_m(\boldsymbol{x})}{\partial x_n} \end{bmatrix}.$$

$(\nabla f_i(x))^T$

此外容易看出，梯度 $\nabla f(\boldsymbol{x})$ 的雅可比矩阵就是 $f(\boldsymbol{x})$ 的海瑟矩阵。

类似于一元函数的 Tayor 展开，多元函数有如下形式的 Taylor 展开：

定理（Taylor 定理）

假设 $f:\mathbb{R}^n \to \mathbb{R}$ 是连续可微的，并且 $\boldsymbol{p} \in \mathbb{R}^n$。则

$$f(\boldsymbol{x}+\boldsymbol{p}) = f(\boldsymbol{x}) + \nabla f(\boldsymbol{x}+t\boldsymbol{p})^{\mathsf{T}}\boldsymbol{p},$$

对于某个 $t \in (0,1)$ 成立。此外，如果 f 是二阶连续可微的，则有

$$\nabla f(\boldsymbol{x}+\boldsymbol{p}) = \nabla f(\boldsymbol{x}) + \int_0^1 \nabla^2 f(\boldsymbol{x}+t\boldsymbol{p})\boldsymbol{p}\,\mathrm{d}t,$$

并且

$$f(\boldsymbol{x}+\boldsymbol{p}) = f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^{\mathsf{T}}\boldsymbol{p} + \frac{1}{2}\boldsymbol{p}^{\mathsf{T}}\nabla^2 f(\boldsymbol{x}+t\boldsymbol{p})\boldsymbol{p},$$

对于某个 $t \in (0,1)$ 成立。

下降方向

定义（下降方向）

对于可微函数 f 和点 $\boldsymbol{x} \in \mathbb{R}^n$，如果存在向量 $\boldsymbol{d}$ 满足

$$\nabla f(\boldsymbol{x})^{\mathsf{T}} \boldsymbol{d} < 0,$$

那么称 $\boldsymbol{d}$ 为 f 在点 $\boldsymbol{x}$ 处的一个下降方向。

注记

由下降方向的定义知：如果 f 在点 $\boldsymbol{x}$ 处存在一个下降方向 $\boldsymbol{d}$，那么 对于任意的 $T > 0$，存在 $t \in (0, T]$，使得

$$f(\boldsymbol{x} + t\boldsymbol{d}) < f(\boldsymbol{x}).$$

因此，在局部最优点处不能有下降方向。

一阶必要条件

若 $f(\boldsymbol{x})$ 在 $\mathbb{R}^n$ 连续可微，$\boldsymbol{x}^*$ 是 $f(\boldsymbol{x})$ 的局部极小点，则

$$\nabla f(\boldsymbol{x}^*) = \left[\frac{\partial f(\boldsymbol{x}^*)}{\partial x_1}, \cdots, \frac{\partial f(\boldsymbol{x}^*)}{\partial x_n}\right]^{\mathsf{T}} = \mathbf{0}$$

$f(\vec{x}+\vec{p}) = f(\vec{x}) + \nabla f(\vec{x})^{\mathsf{T}}\vec{p} + \frac{1}{2}\vec{p}^{\mathsf{T}}\nabla^2 f(\vec{x}+t\vec{p})\vec{p}$

若 $\nabla f(\vec{x}^*) = \vec{0}$，则

$f(\vec{x}^*+\vec{p}) \geq f(\vec{x}^*) \Rightarrow \frac{1}{2}\vec{p}^{\mathsf{T}}\nabla^2 f(\vec{x})\vec{p} \geq 0$.

$\nabla^2 f(\vec{x}^*)$ 半正定.

若 $f(\vec{x}^*+\vec{p}) > f(\vec{x}^*) \Leftrightarrow \frac{1}{2}\vec{p}^{\mathsf{T}}\nabla^2 f(\vec{x})\vec{p} > 0, \forall \vec{p} \neq \vec{0}$

$\nabla^2 f(\vec{x}^*)$ 正定.

二阶最优条件

二阶最优条件

若 $\nabla^2 f(\boldsymbol{x})$ 有定义且在 $\boldsymbol{x}^*$ 的一个开邻域内连续可微，则以下最优性条件成立。

1. 二阶必要条件　若 $\boldsymbol{x}^*$ 是 $f(\boldsymbol{x})$ 的局部极小点，则

$$\nabla f(\boldsymbol{x}^*) = \boldsymbol{0}, \text{ 且 } \nabla^2 f(\boldsymbol{x}^*) \text{ 半正定.}$$

2. 二阶充分条件　若在点 $\boldsymbol{x}^*$ 处有

$$\nabla f(\boldsymbol{x}^*) = \boldsymbol{0}, \quad \text{且 } \nabla^2 f(\boldsymbol{x}^*) \text{ 正定.}$$

则 $\boldsymbol{x}^*$ 是 $f(\boldsymbol{x})$ 的一个局部极小点。

若 $\nabla^2 f(\boldsymbol{x})$ 正定，则可以通过求解 $\nabla f(\boldsymbol{x}) = \boldsymbol{0}$ 得到最优解。

无约束优化问题

无约束优化问题

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} \quad f(\boldsymbol{x})$$

其中 $f:\mathbb{R}^n \to \mathbb{R}$。无约束优化问题是众多优化问题中最基本的问题，它对自变量 $\boldsymbol{x}$ 的取值范围不加限制，无需考虑 $\boldsymbol{x}$ 的可行性。

线搜索方法的直观比喻

可将求解 $f(\boldsymbol{x})$ 的最小值点的过程比喻成下山的过程。假设一个人处于某点 $\boldsymbol{x}$ 处，$f(\boldsymbol{x})$ 表示此地的高度，为了寻找最低点，在点 $\boldsymbol{x}$ 处需要确定两件事情：第一，下一步该向哪一方向行走；第二，沿着该方向行走多远后停下以便选取下一个下山方向。以上这两个因素确定后，便可以一直重复，直至到达 $f(\boldsymbol{x})$ 的最小值点。

线搜索方法

- 线搜索类算法的数学表述为：给定当前迭代点 $\boldsymbol{x}^{(k)}$，首先通过某种算法选取向量 $\boldsymbol{d}^{(k)}$，之后确定正数 α_k，则下一步的迭代点可写作

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{d}^{(k)}.$$

  称 $\boldsymbol{d}^{(k)}$ 为迭代点 $\boldsymbol{x}^{(k)}$ 处的搜索方向，α_k 为相应的步长。

- 这里要求 $\boldsymbol{d}^{(k)}$ 是一个下降方向，即

$$(\boldsymbol{d}^{(k)})^{\mathsf{T}} \nabla f(\boldsymbol{x}^{(k)}) < 0,$$

  这个下降性质保证了沿着此方向搜索函数 f 的值会减小。

- 线搜索类算法的关键是如何选取一个好的方向 $\boldsymbol{d}^{(k)} \in \mathbb{R}^n$ 以及合适的步长 α_k。

先回答如何选取 α_k 这一问题。虽然选取 $\boldsymbol{d}^{(k)}$ 的方法千差万别，但选取 α_k 的方法在不同算法中非常相似。

- 首先构造辅助函数

$$\phi(\alpha) = f(\boldsymbol{x}^{(k)} + \alpha \boldsymbol{d}^{(k)}),$$

其中 $\boldsymbol{d}^{(k)}$ 是给定的下降方向，$\alpha > 0$ 是辅助函数的自变量。

- 函数 $\phi(\alpha)$ 的几何含义非常直观：它是目标函数 $f(\boldsymbol{x})$ 在射线

$$\left\{\boldsymbol{x}^{(k)} + \alpha \boldsymbol{d}^{(k)} : \alpha > 0\right\}$$

上的限制。注意到 $\phi(\alpha)$ 是一个一元函数，研究相对比较方便。

线搜索的目标是选取合适的 α_k 使得 $\phi(\alpha_k)$ 尽可能减小。

精确线搜索法

- 但这并不容易：α_k 应该使得 f 充分下降，与此同时不应在寻找 α_k 上花费过多的计算量。
- 一个自然的想法是寻找 α_k 使得

$$\alpha_k = \arg\min_{\alpha>0} \phi(\alpha),$$

即 α_k 为最佳步长。

- 这种线搜索算法被称为精确线搜索算法。

其中最常见的是梯度下降法。

梯度下降法

- 对于光滑函数 $f(\boldsymbol{x})$，在 $\boldsymbol{x}^{(k)}$ 处，需要选择一个较为合理的 $\boldsymbol{d}^{(k)}$ 作为下降方向。
- 注意到 $\phi(\alpha) = f(\boldsymbol{x}^{(k)} + \alpha \boldsymbol{d}^{(k)})$ 有泰勒展开

$$\phi(\alpha) = f(\boldsymbol{x}^{(k)}) + \alpha \nabla f(\boldsymbol{x}^{(k)})^{\mathsf{T}} \boldsymbol{d}^{(k)} + \mathcal{O}(\alpha^2 \|\boldsymbol{d}^{(k)}\|^2).$$

根据柯西不等式，当 α 足够小时，取 $\boldsymbol{d}^{(k)} = -\nabla f(\boldsymbol{x}^{(k)})$ 会使得函数下降最快。

Cauchy-Schwarz

- 梯度法就是选取下降方向为

$$\boldsymbol{d}^{(k)} = -\nabla f(\boldsymbol{x}^{(k)})$$

的算法，它的迭代格式为

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \alpha_k \nabla f(\boldsymbol{x}^{(k)}).$$

梯度下降法尤其是随机梯度下降法在是机器学习中的重要的优化算法。

最速下降法

- 设 $A \in \mathbb{R}^{n\times n}$ 对称正定，可定义正定二次函数

$$f(\boldsymbol{x}) = \frac{1}{2}(A\boldsymbol{x},\boldsymbol{x}) - (\boldsymbol{b},\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^{\mathsf{T}}A\boldsymbol{x} - \boldsymbol{b}^{\mathsf{T}}\boldsymbol{x}.$$

- 其最优点 $\boldsymbol{x}^*$ 满足

$$\nabla f(\boldsymbol{x}^*) = A\boldsymbol{x}^* - \boldsymbol{b} = \boldsymbol{0} \Longleftrightarrow A\boldsymbol{x}^* = \boldsymbol{b}.$$

即极小值点 $\boldsymbol{x}^*$ 是方程组 $A\boldsymbol{x} = \boldsymbol{b}$ 的解。

反之，考虑

$$\begin{aligned} f(\boldsymbol{x}+\alpha\boldsymbol{y}) &= \frac{1}{2}(\boldsymbol{x}+\alpha\boldsymbol{y})^{\mathsf{T}}A(\boldsymbol{x}+\alpha\boldsymbol{y}) - \boldsymbol{b}^{\mathsf{T}}(\boldsymbol{x}+\alpha\boldsymbol{y}) \\ &= f(\boldsymbol{x}) + \alpha\boldsymbol{y}^{\mathsf{T}}(A\boldsymbol{x}-\boldsymbol{b}) + \frac{1}{2}\alpha^2\boldsymbol{y}^{\mathsf{T}}A\boldsymbol{y}. \end{aligned}$$

若 $\boldsymbol{x}^*$ 是方程组

$$A\boldsymbol{x} = \boldsymbol{b}$$

的解，则有

$$f(\boldsymbol{x}^* + \alpha \boldsymbol{y}) = f(\boldsymbol{x}^*) + \frac{1}{2}\alpha^2 \boldsymbol{y}^\intercal A \boldsymbol{y} \geq f(\boldsymbol{x}^*), \quad A \text{ 对称正定.}$$

即 $\boldsymbol{x}^*$ 是 $f(\boldsymbol{x})$ 的极小值点。

求解方程组 $A\boldsymbol{x} = \boldsymbol{b}$ 和求 $f(\boldsymbol{x})$ 的极小值问题等价。

$$A\boldsymbol{x} = \boldsymbol{b} \Longleftrightarrow \min_{\boldsymbol{x} \in \mathbb{R}^n} f(\boldsymbol{x}).$$

用梯度下降法求解，记

$$\begin{aligned} \phi(\alpha) &= f(\boldsymbol{x} - \alpha \nabla f(\boldsymbol{x})) \\ &= f(\boldsymbol{x}) - \alpha \nabla f(\boldsymbol{x})^\intercal \nabla f(\boldsymbol{x}) + \frac{1}{2}\alpha^2 \nabla f(\boldsymbol{x})^\intercal \nabla^2 f(\boldsymbol{x}) \nabla f(\boldsymbol{x}). \end{aligned}$$

假设有迭代近似解 $\boldsymbol{x}^{(k)}$，则下降方向为

$$-\nabla f(\boldsymbol{x}^{(k)}) = \boldsymbol{b} - A\boldsymbol{x}^{(k)} = \boldsymbol{r}^{(k)}.$$

而且

$$\nabla^2 f(\boldsymbol{x}) = A.$$

选取 α_k 为精确搜索步长，即

$$\begin{aligned}\alpha_k &= \arg\min_{\alpha>0} \phi(\alpha) \\ &= \arg\min_{\alpha>0} \left\{ f(\boldsymbol{x}^{(k)}) - \alpha(\boldsymbol{r}^{(k)})^{\mathsf{T}}\boldsymbol{r}^{(k)} + \frac{1}{2}\alpha^2(\boldsymbol{r}^{(k)})^{\mathsf{T}}A\boldsymbol{r}^{(k)} \right\}.\end{aligned}$$

可得

$$\alpha_k = \frac{\|\boldsymbol{r}^{(k)}\|_2^2}{(\boldsymbol{r}^{(k)})^{\mathsf{T}}A\boldsymbol{r}^{(k)}} = \frac{\|\boldsymbol{r}^{(k)}\|_2^2}{\|\boldsymbol{r}^{(k)}\|_A^2}.$$

这样就得到了最速下降法

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{r}^{(k)}.$$

最速下降法的收敛性

矩阵 $A \in \mathbb{R}^{n\times n}$ 对称正定，$\boldsymbol{x}^*$ 是二次函数

$$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^{\mathsf{T}}A\boldsymbol{x} - \boldsymbol{b}^{\mathsf{T}}\boldsymbol{x}$$

的极小值点，则最速下降法的解满足

$$\|\boldsymbol{x}^{(k)} - \boldsymbol{x}^*\|_A \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n}\right)^k \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^*\|_A.$$

$$\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} = \frac{\frac{\lambda_1}{\lambda_n} - 1}{\frac{\lambda_1}{\lambda_n} + 1}$$

$$\frac{\lambda_1}{\lambda_n} = K_2(A) = \mathrm{cond}_2(A)$$

其中 λ_1 和 λ_n 分别是对称正定阵 A 的最大和最小特征值，而

$$\|\boldsymbol{u}\|_A = (A\boldsymbol{u}, \boldsymbol{u})^{1/2}$$

称为能量模(energy norm)。

若矩阵A病态，则收敛非常慢！

Newton 类方法

- 梯度法仅仅依赖函数值和梯度的信息（即一阶信息），如果函数 $f(\boldsymbol{x})$ 充分光滑，则可以利用二阶导数信息构造下降方向 $\boldsymbol{d}^{(k)}$。
- 牛顿类算法就是利用二阶导数信息来构造迭代格式的算法。由于利用的信息变多，牛顿法的实际表现可以远好于梯度法，但是它对函数 $f(\boldsymbol{x})$ 的要求也相应变高。

对二次连续可微函数 $f(\boldsymbol{x})$，考虑 $f(\boldsymbol{x})$ 在迭代点 $\boldsymbol{x}^{(k)}$ 处的二阶泰勒展开：

$$f(\boldsymbol{x}^{(k)}+\boldsymbol{d}^{(k)}) = f(\boldsymbol{x}^{(k)}) + \nabla f(\boldsymbol{x}^{(k)})^{\mathsf{T}}\boldsymbol{d}^{(k)} + \frac{1}{2}(\boldsymbol{d}^{(k)})^{\mathsf{T}}\nabla^2 f(\boldsymbol{x}^{(k)})\boldsymbol{d}^{(k)} + o(\|\boldsymbol{d}^{(k)}\|^2).$$

$= g(\boldsymbol{d}^{(k)})$

我们想根据这个二阶近似来选取合适的下降方向 $\boldsymbol{d}^{(k)}$。

经典Newton 法

如果忽略上述公式中的高阶项，并将等式右边看成关于 $\boldsymbol{d}^{(k)}$ 的函数对其极小化，可以得到：

$$\nabla^2 f(\boldsymbol{x}^{(k)})\boldsymbol{d}^{(k)} = -\nabla f(\boldsymbol{x}^{(k)}).$$

方程 $\nabla^2 f(\boldsymbol{x}^{(k)})\boldsymbol{d}^{(k)} = -\nabla f(\boldsymbol{x}^{(k)})$ 也被称为牛顿方程。

当 $\nabla^2 f(\boldsymbol{x}^{(k)})$ 非奇异时，更新方向

$$\boldsymbol{d}^{(k)} = -\left(\nabla^2 f(\boldsymbol{x}^{(k)})\right)^{-1} \nabla f(\boldsymbol{x}^{(k)})$$

为牛顿方向。因此经典牛顿法的更新格式为：

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \left(\nabla^2 f(\boldsymbol{x}^{(k)})\right)^{-1} \nabla f(\boldsymbol{x}^{(k)}).$$

此时步长 α_k 恒为 1，称步长为 1 的牛顿法为经典牛顿法。

Karush-Kuhn-Tucker (KKT) 方法

约束优化问题：

$$\begin{aligned} & \min_{\boldsymbol{x}\in\mathbb{R}^n} \quad f(\boldsymbol{x}) \\ \text{subject to} \quad & \boldsymbol{x}\in\mathcal{X}=\{g_i(\boldsymbol{x})\le 0, h_j(\boldsymbol{x})=0\}_{i,j} \end{aligned}$$

可转化为

$$\begin{aligned} & \min_{\boldsymbol{x}} \max_{\boldsymbol{\lambda},\boldsymbol{\mu},\boldsymbol{\lambda}\ge\mathbf{0}} L(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\mu}) \\ = \quad & \min_{\boldsymbol{x}} \max_{\boldsymbol{\lambda},\boldsymbol{\mu},\boldsymbol{\lambda}\ge\mathbf{0}} \left\{ f(\boldsymbol{x}) + \sum_{i=1}^{k} \lambda_i g_i(\boldsymbol{x}) + \sum_{j=1}^{l} \mu_j h_j(\boldsymbol{x}) \right\}. \end{aligned}$$

函数 $L(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\mu})$ 称为拉格朗日函数。$\boldsymbol{\lambda}$ 和 $\boldsymbol{\mu}$ 称为 KKT 乘子。 而 $\min_{\boldsymbol{x}} \max_{\boldsymbol{\lambda},\boldsymbol{\mu}}$ 表示求 $\boldsymbol{x}$ 使得 L 对 $\boldsymbol{\lambda},\boldsymbol{\mu}$ 取得的极大值达到最小。

KKT 方法

1. 若 $\boldsymbol{x} \in \mathcal{X}$，即为可行点，则

$$\max_{\boldsymbol{\lambda},\boldsymbol{\mu},\boldsymbol{\lambda}\geq\mathbf{0}} L(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\mu}) = f(\boldsymbol{x}).$$

因此最优的可行点没有发生变化。

2. 反之，任何非可行点 $\boldsymbol{x}$，若 $g_i(\boldsymbol{x}) > 0$，则令 $\lambda_i = +\infty$，其余的因子全为零，则

$$\max_{\boldsymbol{\lambda},\boldsymbol{\mu},\boldsymbol{\lambda}\geq\mathbf{0}} L(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\mu}) = +\infty.$$

其他情形也有类似的结论。

因此若存在可行点，则非可行点不可能达到最优。

KKT 条件

KKT 条件

若 $\boldsymbol{x}^*$ 是一个最优解，则存在 KKT 因子 $\boldsymbol{\lambda}^*$ 和 $\boldsymbol{\mu}^*$ 满足 KKT 条件：

1. 拉格朗日平稳性：

$$\nabla L(\boldsymbol{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) = \nabla f(\boldsymbol{x}^*) + \sum_{i=1}^{k} \lambda_i^* \nabla g_i(\boldsymbol{x}^*) + \sum_{j=1}^{l} \mu_j^* \nabla h_j(\boldsymbol{x}^*) = \boldsymbol{0}.$$

2. 原可行性：$g_i(\boldsymbol{x}^*) \le 0$ 且 $h_j(\boldsymbol{x}^*) = 0,\ \forall i, j$。
3. 对偶可行性：$\boldsymbol{\lambda}^* \ge \boldsymbol{0}$。
4. 互补松弛性：$\lambda_i^* g_i(\boldsymbol{x}^*) = 0,\ \forall i$。

KKT 条件是最优解的一个必要条件。若原问题是凸的，则为充分条件。

互补松弛性

为什么要求 $\lambda_i^* g_i(\boldsymbol{x}^*) = 0$?

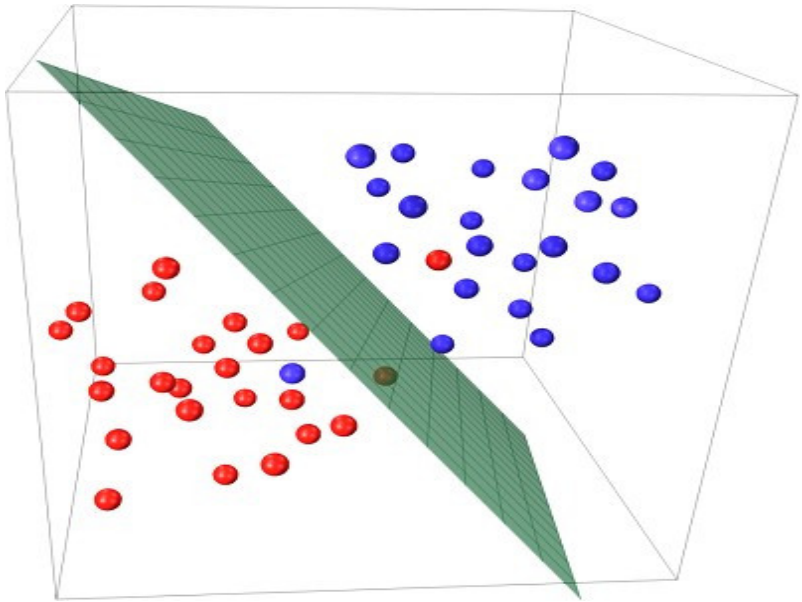
1. 若 $\boldsymbol{x}^*$ 是可行解，则有 $g_i(\boldsymbol{x}^*) \leq 0$。
2. 若 $g_i(\boldsymbol{x}^*)$ 是有效的（active），即 $g_i(\boldsymbol{x}^*) = 0$，则 $\lambda_i^* g_i(\boldsymbol{x}^*) = 0$ 自然成立。
3. 若 $g_i(\boldsymbol{x}^*)$ 是非有效的（inactive），即 $g_i(\boldsymbol{x}^*) < 0$，则
   - 为了在拉格朗日函数中极大化 $\lambda_i g_i(\boldsymbol{x}^*)$ 这一项，因为 $\lambda_i \geq 0$，则有 $\lambda_i^* = 0$。
   - 同样有 $\lambda_i^* g_i^*(\boldsymbol{x}^*) = 0$。
4. 因此从互补松弛性可知：
   - $\lambda_i^* > 0$ 意味着 $g_i(\boldsymbol{x}^*) = 0$。
   - 一旦求出 $\boldsymbol{x}^*$，通过判断 $\lambda_i^* > 0$ 可以很快找出起作用的不等式约束。

支持向量机(Support Vector Machine)

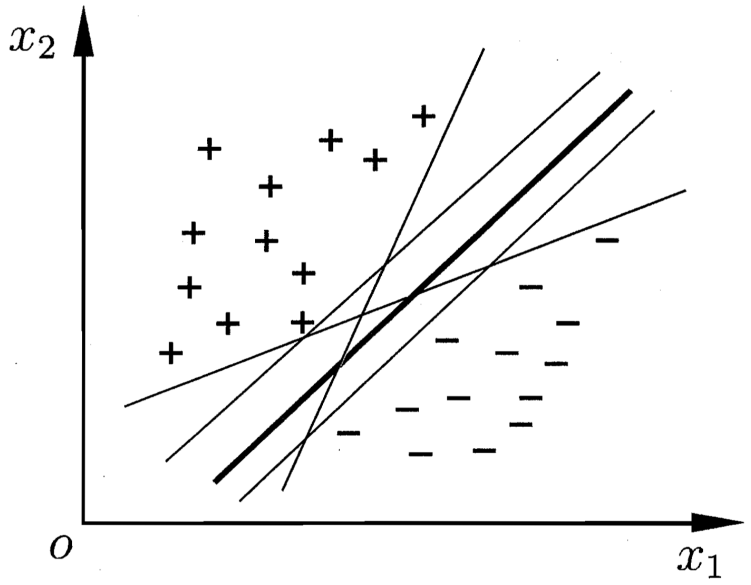
考虑训练集

$$\{(\boldsymbol{x}_1, c_1), (\boldsymbol{x}_2, c_2), \ldots, (\boldsymbol{x}_m, c_m)\}, \quad \boldsymbol{x}_i \in \mathbb{R}^n.$$

其中 $c_i \in \{-1, +1\}$ 是表明 $\boldsymbol{x}_i$ 所属类的指标。
分类学习最基本的想法就是基于训练集 D 在样本空间中找到一个划分平面把不同类别的样本分开。



但是能将训练样本分开的划分超平面有很多个。



样本空间中，划分超平面可用如下的方程来描述

$$\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b = 0.$$

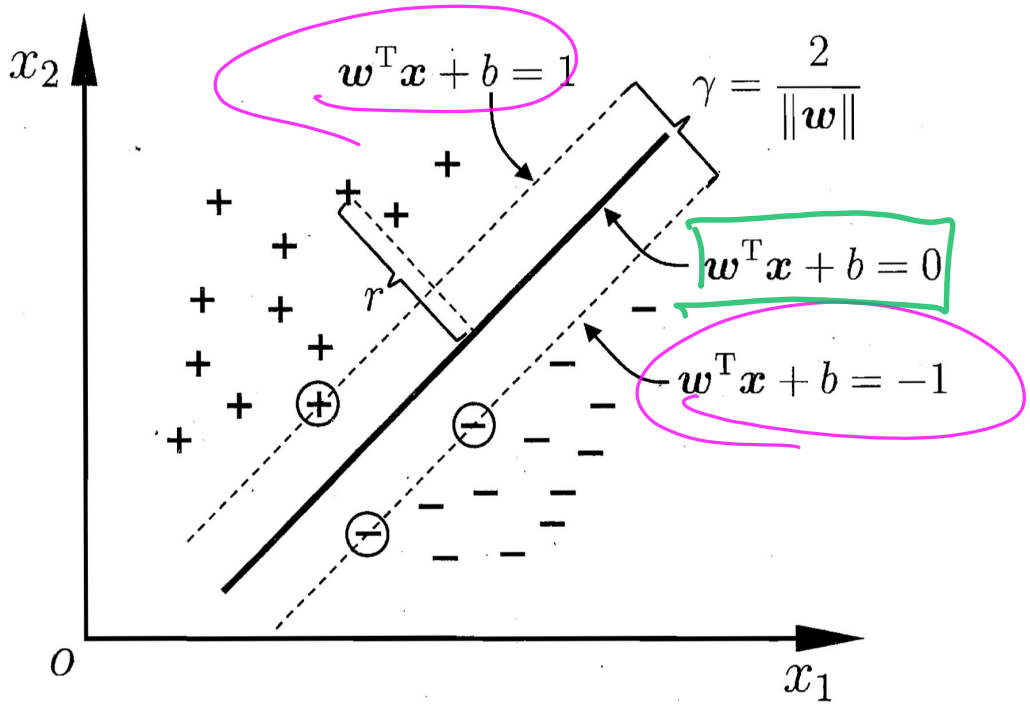
向量 $\boldsymbol{w}$ 是划分超平面的法向量；b 是位移，是超平面和原点的距离。
样本空间任一点 $\boldsymbol{x}$ 到划分超平面 $(\boldsymbol{w}, b)$ 的距离

$$\gamma = \frac{|\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b|}{\|\boldsymbol{w}\|}.$$

若超平面 $(\boldsymbol{w}, b)$ 能将训练样本正确分类，即对 $(\boldsymbol{x}_i, c_i) \in D$，若 $c_i = +1$，则有 $\boldsymbol{w}^T\boldsymbol{x}_i + b > 0$；若 $c_i = -1$，则有 $\boldsymbol{w}^T\boldsymbol{x}_i + b < 0$。令

$$\begin{cases} \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i + b \geq +1, & c_i = +1; \\ \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i + b \leq -1, & c_i = -1 \end{cases}$$

如下图所示，距离超平面最近的这几个训练样本点使得上式等号成立，它们被称为“支持向量”（support vector）。



两个不同类支持向量到超平面的距离之和为

$$\gamma = \frac{2}{\|\boldsymbol{w}\|}$$

它被称为“间隔”（margin）。

想找到具有“最大间隔”的划分超平面，亦即找到参数 $\boldsymbol{w}$ 和 b 使得 γ 最大，即

$$\begin{aligned} &\max_{\boldsymbol{w},b} \quad \frac{2}{\|\boldsymbol{w}\|} \\ &s.t \quad c_i(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i + b) \geq 1, \quad i = 1, 2, \cdots, m \end{aligned}$$

显然，为了最大化间隔，仅需最大化 $\|\boldsymbol{w}\|^{-1}$，这等价于最小化 $\|\boldsymbol{w}\|^2$。

则优化问题可改写为支持向量机（SVM）的基本型。

$$\begin{cases} \min\limits_{\boldsymbol{w},b} \quad \frac{1}{2}\|\boldsymbol{w}\|^2 \\ s.t \quad c_i(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i + b) \geq 1, \quad i = 1, 2, \cdots, m \end{cases}$$

SVM 的求解

对 SVM 问题，可以定义拉格朗日函数

$$L(\boldsymbol{w}, b, \boldsymbol{\lambda}) = \frac{1}{2}\|\boldsymbol{w}\|^2 - \sum_{i=1}^{m} \lambda_i \left[c_i(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i + b) - 1\right].$$

其 KKT 条件为

$$\nabla_{\boldsymbol{w}} L = \boldsymbol{w} - \sum_{i=1}^{m} \lambda_i \boldsymbol{x}_i = 0 \Longleftrightarrow \boldsymbol{w} = \sum_{i=1}^{m} \lambda_i c_i \boldsymbol{x}_i,$$

$$\nabla_b L = -\sum_{i=1}^{m} \lambda_i c_i = 0 \Longleftrightarrow \sum_{i=1}^{m} \lambda_i c_i = 0,$$

$$\lambda_i \left[c_i(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i + b) - 1\right] = 0.$$

方程组求根

非线性方程和方程组

$$F(\boldsymbol{x}) = \mathbf{0},\quad \boldsymbol{x} \in \mathbb{R}^n,\quad F(\boldsymbol{x}) \in \mathbb{R}^n.$$

设 $F(\boldsymbol{x})$ 的分量为 $F_i(\boldsymbol{x}) = 0, 1 \le i \le n$，则求解 $F(\boldsymbol{x}) = \mathbf{0}$ 可转化为一个优化问题。

记 $f(\boldsymbol{x}) = \sum_{i=1}^{n} F_i^2(\boldsymbol{x})$，则

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} f(\boldsymbol{x}) \Longleftrightarrow F(\boldsymbol{x}) = \mathbf{0}.$$

非线性方程组求解可以转化为优化问题，反之亦然。

单个方程

当 $n = 1$ 时变为单变量的单个方程

$$f(x) = 0.$$

单个方程常见的有多项式形式的代数方程

$$a_n x^n + a_{n-1} x^{n-1} + \cdots + a_1 x + a_0 = 0,$$

代数方程只有 $n = 1, 2, 3, 4$ 时有解析的求根公式，$n \geq 5$ 时，没有通用的求根公式。

除了代数方程外。另一种常见的方程是超越方程如

$$3x^2 - e^x = 0, \quad x = \frac{1}{2} + \sin x.$$

数学家简介 (Cardano)

卡尔达诺*(1501-1576)*意大利数学家、医学家、物理学家， 是意大利文艺复兴时期百科全书式的学者。一生共写了各类文章、书籍*200*多种，现存材料就有约*7000*页。他的数学贡献体现在几本著作中：《论掷骰游戏》给出一些概率论的基本概念和定理。 得到所谓“幂定理”等结果；他最重要的著作《大术》首次公布了三、四次代数方程的一般解法， 确认了高于一次的代数方程多于一个根，已知方程的一个根可将方程降阶，指出方程的根与系数间的某些关系， 利用反复实施代换的方法求得方程的近似解。在解方程中使用了虚数等。在其当中关于一般二次代数方程的求根公式今称“卡当公式”或“卡尔达诺公式”。 他的另外两部著作《事物之精妙》与《世间万物》包含了大量力学、机械学、天文学、化学、生物学等自然科学与技术的知识，还有密码术、炼金术，以及占星术等内容。被誉为当时最好的百科全书， 曾多次印刷，广泛流传于欧洲大陆。作为医生既精于诊断开方，也专于外科手术。他还在理论上第一个阐述了诊断斑疹伤寒病的方法。对生理学和心理学的问题提出自己的见解。



在理论上线性方程组 $\boldsymbol{Ax} = \boldsymbol{b}$ 只要 A^{-1} 存在，则解存在唯一，而非线性方程组解的存在唯一性问题没有完全解决。

例

$\mathbb{R}^2$ 上的两条抛物线

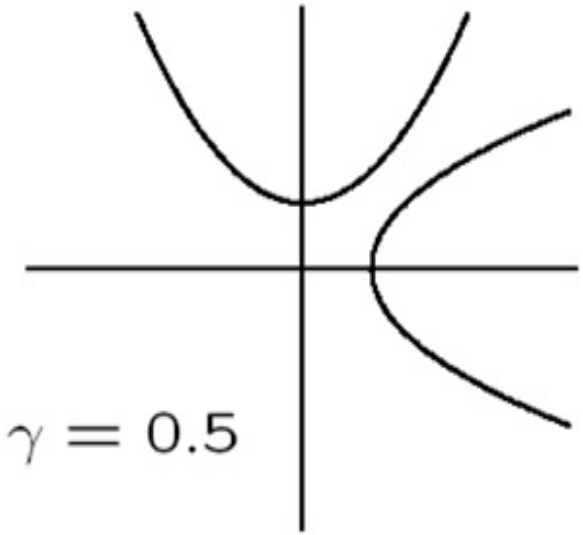
$$\begin{cases} f_1(x_1, x_2) = x_1^2 - x_2 + \gamma = 0, \\ f_2(x_1, x_2) = -x_1 + x_2^2 + \gamma = 0, \end{cases}$$

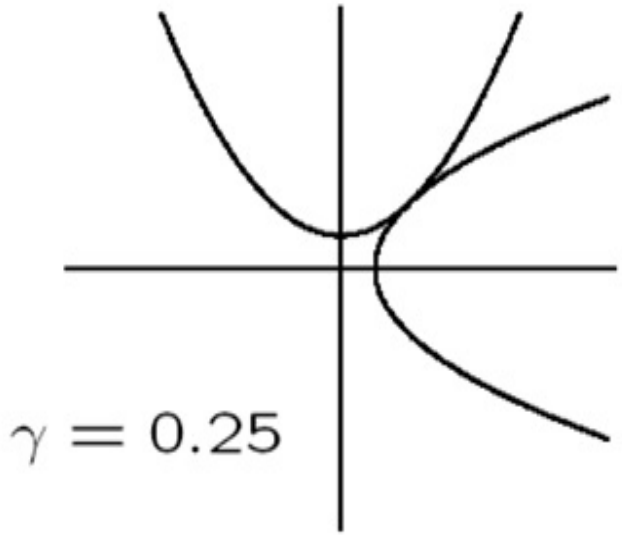
$x_2 = x_1^2 + \gamma$ ↙2次

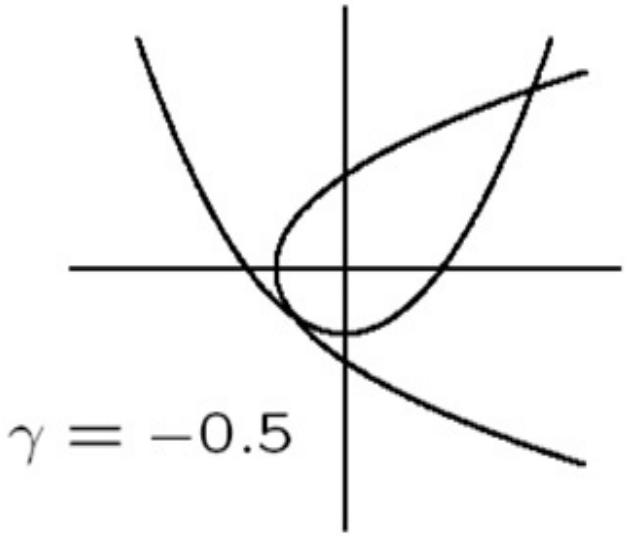
$-x_1 + (x_1^2+\gamma)^2 + \gamma = 0$ ← 4次

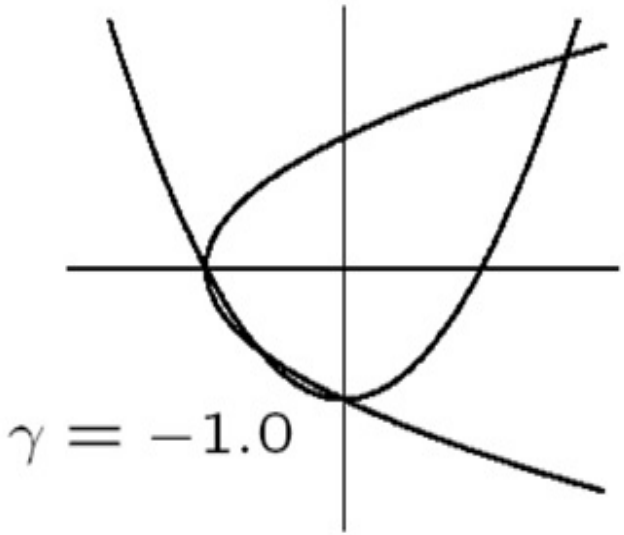
它们的交点就是方程组的解，对 $-1 \le \gamma \le 1$，

1. $\gamma = 0.5$， 无解；
2. $\gamma = \frac{1}{4}$， 一个解$x_1 = x_2 = \frac{1}{2}$；
3. $\gamma = 0$， 两个解$x_1 = x_2 = 0; x_1 = x_2 = 1$；
4. $\gamma = -1$， $x_1 = -1, x_2 = 0$； $x_1 = 0, x_2 = -1$； $x_1 = x_2 = \frac{1}{2}(1 \pm \sqrt{5})$。


$\gamma = 0.5$


$\gamma = 0.25$


$\gamma = -0.5$


$\gamma = -1.0$

还有无穷多解的方程组，如

例

$$\begin{cases} f_1(x_1, x_2) = \sin \frac{\pi}{2} x_1 - x_2 = 0 \\ f_2(x_1, x_2) = x_2 - 1/2 = 0 \end{cases}$$

所以对非线性方程组只能给出解在域 D 中存在唯一的充分条件，在此前提下讨论求解的方法。

通常都用迭代法求解非线性方程，因为用直接消去法即使能消成一个变量的单个方程，还会出现大量增根，而且数值上也是不稳定的。只有小规模的特殊的非线性方程才可能用直接法求解。

高次代数方程求根是病态问题 Wilkinson多项式.

向量值函数是指映射 $F: D \subset \mathbb{R}^n \to \mathbb{R}^m$：

$$F(\boldsymbol{x}) = \begin{pmatrix} F_1(x_1, x_2, \cdots, x_n) \\ F_2(x_1, x_2, \cdots, x_n) \\ \cdots \\ F_m(x_1, x_2, \cdots, x_n) \end{pmatrix}$$

定义（向量函数的连续性）

设 $F: D \subset \mathbb{R}^n \to \mathbb{R}^m$，$\boldsymbol{x}_0 \in D$，若 $\forall \epsilon > 0$，$\exists \delta > 0$，使得

$$\forall \boldsymbol{x} \in B(\boldsymbol{x}_0, \delta) \subset D, \text{ 都有 } \|F(\boldsymbol{x}) - F(\boldsymbol{x}_0)\| < \epsilon$$

则称函数 F 在 $\boldsymbol{x}_0$ 点连续。设 $F: D \subset \mathbb{R}^n \to \mathbb{R}^m$ 在 D 中的每一点连续，称 F 在 D 上连续。

$\vec{x} \in B(\vec{x}_0, \delta) \Leftrightarrow \|\vec{x} - \vec{x}_0\| < \delta$

定义（一致连续性）

设 $K \subset D$，若 $\forall \epsilon > 0$，$\exists \delta > 0$，使得

$$\forall \boldsymbol{x}, \boldsymbol{y} \in K, \|\boldsymbol{x} - \boldsymbol{y}\| < \delta \quad \text{都有} \quad \|F(\boldsymbol{x}) - F(\boldsymbol{y})\| < \epsilon$$

则称 F 在 K 上一致连续。

定义（Lipschitz 连续）

设 $K \subset D$，若 $\forall \boldsymbol{x}, \boldsymbol{y} \in K$，满足

$$\|F(\boldsymbol{x}) - F(\boldsymbol{y})\| < L\|\boldsymbol{x} - \boldsymbol{y}\|^p$$

$$\begin{cases} \dfrac{dy}{dt} = f(t, y) \\ y(0) = y_0 \end{cases}$$

若 $0 < p < 1$，称 F 在 K 上Hölder连续。p 称为指标。 若 $p = 1$，称 F 在 K 上Lipschitz连续。

$$|f(t, y_1) - f(t, y_2)| \le L|y_1 - y_2|$$

收敛性

为讨论迭代法，有必要讨论一下 $\mathbb{R}^n$ 中的收敛性(拓扑结构)。

定义（向量序列的收敛性）

设 $\{\boldsymbol{x}^{(k)}\}_{k=0}^{\infty}$ 是赋范空间 $(\mathbb{R}^n, \|\cdot\|)$ 中的向量序列。若存在 $\boldsymbol{x} \in \mathbb{R}^n$，使得

$$\lim_{k\to\infty} \|\boldsymbol{x}^{(k)} - \boldsymbol{x}\| = 0,$$

则称 $\{\boldsymbol{x}^{(k)}\}$ 收敛于 $\boldsymbol{x}$，记为 $\lim\limits_{k\to\infty} \boldsymbol{x}^{(k)} = \boldsymbol{x}$。

$c_1\|\vec{u}\|_\alpha \le \|\vec{u}\|_\beta \le c_2\|u\|_\alpha$

$\|\vec{x}^{(k)}-\vec{x}\|_\alpha \le \frac{1}{c_1}\|\vec{x}^{(k)}-\vec{x}\|_\beta$

$\|\vec{x}^{(k)}-\vec{x}\|_\beta \le c_2\|\vec{x}^{(k)}-\vec{x}\|_\alpha$.

上面定义的收敛性表面上看来依赖于 $\mathbb{R}^n$ 中的范数，但由于有限维线性空间中的所有范数都是等价的，向量序列的收敛性不依赖于范数的选择。

定理（向量序列收敛的判定条件）

设 $\boldsymbol{x}^{(k)} = (x_1^{(k)}, x_2^{(k)}, \cdots, x_n^{(k)})^{\mathsf{T}}$, $\boldsymbol{x} = (x_1, x_2, \cdots, x_n)^{\mathsf{T}}$, 则

$$\lim_{k\to\infty} \boldsymbol{x}^{(k)} = \boldsymbol{x} \Longleftrightarrow \lim_{k\to\infty} x_i^{(k)} = x_i,\ \forall i = 1, 2, \cdots, n.$$

亦即向量序列收敛等价于其分量序列收敛。

证明: $\lim_{k\to\infty} \vec{x}^{(k)} = \vec{x} \Leftrightarrow \lim_{k\to\infty} \|\vec{x}^{(k)} - \vec{x}\| = 0.$

$\Leftrightarrow \lim_{k\to\infty} \|\vec{x}^{(k)} - \vec{x}\|_\infty = 0.$

$\Leftrightarrow \lim_{k\to\infty} \max_i |x_i^{(k)} - x_i| = 0$

$\Leftrightarrow \lim_{k\to\infty} |x_i^{(k)} - x_i| = 0,\ 1 \le i \le n.$

$\Leftrightarrow \lim_{k\to\infty} x_i^{(k)} = x_i,\ 1 \le i \le n.$

定义（向量值函数的可导性）

设 $F: D \subset \mathbb{R}^n \to \mathbb{R}^m$，$\boldsymbol{x} \in D$。若存在 $A(\boldsymbol{x}) \in \mathbb{R}^{m\times n}$，使得

$$\lim_{\boldsymbol{h}\to\boldsymbol{0},\boldsymbol{x}+\boldsymbol{h}\in D} \frac{\|F(\boldsymbol{x}+\boldsymbol{h}) - F(\boldsymbol{x}) - A(\boldsymbol{x})\boldsymbol{h}\|}{\|\boldsymbol{h}\|} = 0.$$

则称 F 在 $\boldsymbol{x}$ 点可导（可微）。记作 $F'(\boldsymbol{x}) = A(\boldsymbol{x}) = \frac{\partial F}{\partial \boldsymbol{x}}(\boldsymbol{x})$。

若函数 F 在 $\boldsymbol{x} \in D$ 可微，则 F 在 $\boldsymbol{x}$ 点连续。

$\forall \varepsilon>0$, $\exists \delta>0$, s.t. $\|\vec{h}\|<\delta$, 有: $\|F(\vec{x}+\vec{h})-F(\vec{x})-A(\vec{x})\vec{h}\|<\varepsilon\|\vec{h}\|$.

(三角不等式) $\to \|\|\vec{u}\|-\|\vec{v}\|\| \le \|\vec{u}-\vec{v}\|$.

则: $\|F(\vec{x}+\vec{h})-F(\vec{x})\| - \|A(\vec{x})\vec{h}\| \le \|F(\vec{x}+\vec{h})-F(\vec{x})-A(\vec{x})\vec{h}\| < \varepsilon\|\vec{h}\|$.

则: $\|F(\vec{x}+\vec{h})-F(\vec{x})\| \le \|A(\vec{x})\vec{h}\| + \varepsilon\|\vec{h}\| \le (\|A(\vec{x})\|+\varepsilon)\|\vec{h}\|$.

连续.

数学家简介 (Abel)

尼尔斯·亨利克·阿贝尔（*1802*年*8*月*5*日－*1829*年*4*月*6*日），挪威数学家，在很多数学领域做出了开创性的工作。 他最著名的一个结果是首次完整给出了高于四次的一般代数方程没有一般形式的代数解的证明。这个问题是他那时最著名的未解决问题之一， 悬疑达*250*多年。他也是椭圆函数领域的开拓者，阿贝尔函数的发现者。除了五次方程之外，他还研究了更广的一类代数方程，后人发现这是具有交换的伽罗瓦群的方程。 为了纪念他，后人称交换群为阿贝尔群。 阿贝尔还研究过无穷级数，得到了一些判别准则以及关于幂级数求和的定理。这些工作使他成为分析学严格化的推动者。埃尔米特曾说：阿贝尔留下的思想可供数学家们工作*150*年。 尽管阿贝尔成就极高，却在生前没有得到认可，他的生活非常贫困，死时只有*27*岁。数学界的诺贝尔奖*Abel*奖。



迭代法与直接法不同，它并不试图在有限计算步中得到问题的真解，而是从若干个初始向量出发，用一个适当的算法，得到一个近似解的序列 $\{\boldsymbol{x}^{(k)}\}_{k=0}^{\infty}$。

一般 $\boldsymbol{x}^{(k+1)}$ 的计算公式可写成如下形式

$$\boldsymbol{x}^{(k+1)} = F_k\left(\boldsymbol{x}^{(k)}, \boldsymbol{x}^{(k-1)}, \cdots, \boldsymbol{x}^{(k-m)}\right), k = 0, 1, \cdots$$

- 若 $m \geq 1$，则称为多步迭代法(multistep iterative method)。
- 若 $m = 0$，即 $\boldsymbol{x}^{(k+1)}$ 的计算只与 $\boldsymbol{x}^{(k)}$ 相关，即

$$\boldsymbol{x}^{(k+1)} = F_k(\boldsymbol{x}^{(k)}), k = 0, 1, \cdots$$

则称其为单步法(one step method)。

下降方向法：

$$\vec{x}^{(k+1)} = \vec{x}^{(k)} + \alpha_k \vec{d}^{(k)}$$

- 如果 F_k 是线性映射，即

$$\boldsymbol{x}^{(k+1)} = B_k \boldsymbol{x}^{(k)} + \boldsymbol{f}_k, \quad k = 0, 1, \cdots$$

仿射变换.

其中

$$B_k \in \mathbb{R}^{n\times n}, \quad \boldsymbol{f}_k \in \mathbb{R}^n,$$

则称该方法为线性单步迭代法，B_k 称为迭代矩阵(iterative matrix)。

- 进一步，若 B_k 和 $\boldsymbol{f}_k$ 与 k 无关，即

$$\boldsymbol{x}^{(k+1)} = B\boldsymbol{x}^{(k)} + \boldsymbol{f}, \quad k = 0, 1, \cdots$$

则称该方法为线性定常单步迭代法。求解线性方程组的 Jacobi、Gauss-Seidal 和 SOR 法都是线性定常单步迭代法。

定义（收敛阶）

迭代法称为是 p 阶收敛到 $\boldsymbol{x}^*$ 的，若算法产生的序列 $\{\boldsymbol{x}^{(k)}\}$ 满足

$$\exists C > 0: \quad \frac{\|\boldsymbol{x}^{(k+1)} - \boldsymbol{x}^*\|}{\|\boldsymbol{x}^{(k)} - \boldsymbol{x}^*\|^p} \leq C, \ \forall k \geq k_0.$$

- 若 $p = 1$，算法收敛，则必有 $C < 1$， 此时 C 称为收敛因子。
- 线性方程组的迭代法的收敛性不依赖于初值的选取，具有全局收敛性。
- 而非线性方程的迭代法的收敛性依赖于 初值的选取，一般只有局部收敛性（即要求初值 $\boldsymbol{x}^{(0)}$ 在 $\boldsymbol{x}^*$ 的一个小邻域内）。相应的对区间内任意初值收敛的算法称为全局收敛到 $\boldsymbol{x}^*$。

1. $p=1$ 线性收敛。若

$$\lim_{k\to\infty}\frac{\|\boldsymbol{x}^{(k+1)}-\boldsymbol{x}^*\|}{\|\boldsymbol{x}^{(k)}-\boldsymbol{x}^*\|}=0$$

称超线性收敛。

2. $p=2$ 平方收敛；

3. 若 $\{\boldsymbol{x}^{(k)}\}_{k=0}^{\infty}$ 超线性收敛于 $\boldsymbol{x}^*$，则

$$\lim_{k\to\infty}\frac{\|\boldsymbol{x}^{(k+1)}-\boldsymbol{x}^{(k)}\|}{\|\boldsymbol{x}^{(k)}-\boldsymbol{x}^*\|}=1.$$

因为

$$\left|\frac{\|\boldsymbol{x}^{(k+1)}-\boldsymbol{x}^{(k)}\|}{\|\boldsymbol{x}^{(k)}-\boldsymbol{x}^*\|}-1\right|\le\frac{\|\boldsymbol{x}^{(k+1)}-\boldsymbol{x}^*\|}{\|\boldsymbol{x}^{(k)}-\boldsymbol{x}^*\|}\to 0.$$

迭代法的收敛终止条件

$A\vec{x}=\vec{b}$ 迭代法：$\vec{x}^{(k+1)}=B\vec{x}^{(k)}+\vec{f}$.

(1) $\|\vec{x}^{(k+1)}-\vec{x}^{(k)}\|<\varepsilon_0$, (10^{-6}), 则迭代终止.

若算法超线性收敛，则：$\|\vec{x}^{(k+1)}-\vec{x}^{(k)}\|\approx\|\vec{x}^{(k)}-\vec{x}\|$ ✓

但：$\|\vec{x}^{(k+1)}-\vec{x}^{*}\|\le\frac{\|B\|}{1-\|B\|}\|\vec{x}^{(k+1)}-\vec{x}^{(k)}\|$

收敛$\Leftrightarrow\|B\|<1$. 若 $\|B\|\sim 1$, 则 $\|\vec{x}^{(k+1)}-\vec{x}^{(k)}\|\ll 1 \not\Rightarrow \|\vec{e}^{(k)}\|\ll 1$.

(2) 残差 $\|\vec{r}^{(k)}\|=\|\vec{b}-A\vec{x}^{(k)}\|<\varepsilon_0$, 则迭代终止.

若A病态，$\|\vec{r}^{(k)}\|\ll 1 \not\Rightarrow \|\vec{e}^{(k)}\|\ll 1$.

(3) 最大迭代次数！

定义（不动点）

设 $G: D \subset \mathbb{R}^n \to \mathbb{R}^n$，若 $\boldsymbol{x}^* \in D$ 满足 $\boldsymbol{x}^* = G(\boldsymbol{x}^*)$，则称 $\boldsymbol{x}^*$ 为映射 G 的不动点。

把方程组的求根问题等价的转化为某个映射的不动点问题：

$$\underbrace{F(\boldsymbol{x}) = \boldsymbol{0}}_{\text{求根}} \Longleftrightarrow \underbrace{\boldsymbol{x} = G(\boldsymbol{x})}_{\text{求不动点}}$$

$\vec{x}^{(k+1)} = G(\vec{x}^{(k)})$

$A\vec{x} = \vec{b} \Leftrightarrow \frac{1}{2}A\vec{x} - \frac{1}{2}\vec{b} = \vec{0}$，$\alpha \neq 0$，则

$\vec{x} + \frac{1}{2}A\vec{x} - \frac{1}{2}\vec{b} = (I + \frac{1}{2}A)\vec{x} - \frac{1}{2}\vec{b} = \vec{x}$

$G(\vec{x}) = (I + \frac{1}{2}A)\vec{x} - \frac{\vec{b}}{2}$，$\alpha \neq 0$. 无穷多个！

定义（压缩映射）

假定 $G: D \subset \mathbb{R}^n \to \mathbb{R}^n$，若 $\alpha \in (0,1)$，有

$$\|G(\boldsymbol{x}) - G(\boldsymbol{y})\| \le \alpha \|\boldsymbol{x} - \boldsymbol{y}\|, \ \forall \boldsymbol{x}, \boldsymbol{y} \in D_0 \subset D$$

则称 G 在 D_0 上为压缩映射。α 为压缩常数。

$\vec{x}^{(k+1)} = G(\vec{x}^{(k)})$, $\vec{x}^* = G(\vec{x}^*)$

$$\|\vec{x}^{(k+1)} - \vec{x}^*\| = \|G(\vec{x}^{(k)}) - G(\vec{x}^*)\| \le \alpha \|\vec{x}^{(k)} - \vec{x}^*\|.$$

$\vec{e}^{(k+1)}$

$$= \alpha \|G(\vec{x}^{(k-1)}) - G(\vec{x}^*)\|$$

$$\le \alpha^2 \|\vec{x}^{(k-1)} - \vec{x}^*\| \le \cdots$$

$$\le \alpha^k \|\vec{x}^{(0)} - \vec{x}^*\| = \alpha^k \|\vec{e}^{(0)}\|.$$

$$\|\vec{e}^{(k+1)}\| \le \alpha^k \|\vec{e}^{(0)}\|.$$

压缩映射对范数的依赖性

映射压缩性依赖于范数的选择。

$$G(\boldsymbol{x}) = A\boldsymbol{x}, \quad A = \begin{bmatrix} 0.1 & 0.9 \\ 0 & 0.1 \end{bmatrix}$$

由于 $\|A\|_2 = \sqrt{\rho(A^\intercal A)} \leq 0.83$，于是

$$\|G(\boldsymbol{x}) - G(\boldsymbol{y})\|_2 \leq \|A\|_2 \|\boldsymbol{x} - \boldsymbol{y}\|_2 \leq 0.83 \|\boldsymbol{x} - \boldsymbol{y}\|_2$$

是压缩的。但

$$\begin{aligned} \|G([1,1]) - G([0,0])\|_\infty &= \|[1, 0.1]\|_\infty \\ &= 1 = \|[1,1] - [0,0]\|_\infty \end{aligned}$$

因而在无穷范数下不压缩。

定理（压缩映射原理）

设 $G: D \subset \mathbb{R}^n \to \mathbb{R}^n$ 在闭集 $D_0 \subset D$ 上是压缩映射，且 G 把 D_0 映入自身，即 $GD_0 \subset D_0$，则 G 在 D_0 上有唯一的不动点。

证明：设 $\vec{x}^{(0)} \in D_0$，定义：$\vec{x}^{(k+1)} = G(\vec{x}^{(k)})$，$k \geq 0$，

其为 $GD_0 \subset D_0$，则 $\{\vec{x}^{(k)}\}_{k\geq 0} \subset D_0$.

想证明 $\{\vec{x}^{(k)}\}$ 是Cauchy列：$\forall \varepsilon > 0$，$\exists N_0 \in \mathbb{N}$，$\forall k \geq N_0$，$\forall p \in \mathbb{N}$，有 $\|\vec{x}^{(k+p)} - \vec{x}^{(k)}\| < \varepsilon$

$$\|\vec{x}^{(k+1)} - \vec{x}^{(k)}\| = \|G(\vec{x}^{(k)}) - G(\vec{x}^{(k-1)})\| \leq \alpha \|\vec{x}^{(k)} - \vec{x}^{(k-1)}\|$$

$$= \alpha \|G(\vec{x}^{(k-1)}) - G(\vec{x}^{(k-2)})\| \leq \alpha^2 \|\vec{x}^{(k-1)} - \vec{x}^{(k-2)}\|$$

$$\leq \cdots \leq \alpha^k \|\vec{x}^{(1)} - \vec{x}^{(0)}\|.$$

$$\|\vec{x}^{(k+p)} - \vec{x}^{(k)}\| = \|\vec{x}^{(k+p)} - \vec{x}^{(k+p-1)} + \vec{x}^{(k+p-1)} - \cdots + \vec{x}^{(k+1)} - \vec{x}^{(k)}\|$$

$$\leq \sum_{j=1}^{p} \|\vec{x}^{(k+j)} - \vec{x}^{(k+j-1)}\|$$

$$\le (1+\alpha^2+\cdots+\alpha^p)\|\vec{x}^{(k+1)}-\vec{x}^{(k)}\|$$

$$\le \frac{1}{1-\alpha}\|\vec{x}^{(k+1)}-\vec{x}^{(k)}\| \le \frac{\alpha^k}{1-\alpha}\|\vec{x}^{(1)}-\vec{x}^{(0)}\|$$

则 $\{\vec{x}^{(k)}\}_{k\ge 0}$ 是Cauchy列，收敛，$\lim_{k\to\infty}\vec{x}^{(k)}=\vec{x}^{*}\in D_0$.

$\vec{x}^{*}=\lim_{k\to\infty}\vec{x}^{(k)}=\lim_{k\to\infty}G(\vec{x}^{(k-1)})$?

(D0闭)

$G(\lim_{k\to\infty}\vec{x}^{(k-1)})=G(\vec{x}^{*})$

不动点迭代

把求解方程组等价地转化为不动点问题

$$F(\boldsymbol{x}) = \boldsymbol{0} \Longleftrightarrow \boldsymbol{x} = G(\boldsymbol{x}).$$

构造不动点迭代格式求解不动点问题 $\boldsymbol{x} = G(\boldsymbol{x})$:

$$\begin{cases} \boldsymbol{x}^{(0)} \in \mathbb{R}^n, \\ \boldsymbol{x}^{(k+1)} = G(\boldsymbol{x}^{(k)}). \end{cases}$$

这是一个单步迭代法。

由压缩映像原理，$G(\boldsymbol{x})$ 满足压缩，映内则

$$\lim_{k\to\infty} \boldsymbol{x}^{(k)} = \boldsymbol{x}^* = G(\boldsymbol{x}^*).$$

局部收敛性

- 前面的压缩映射原理是在整个区域 $D_0 \subset D$ 上满足压缩条件，它的收敛性是大范围收敛，且定理本身包含了不动点 $\boldsymbol{x}^*$ 的存在唯一性。
- 但是很多情况下，假定 $G(\boldsymbol{x})$ 的不动点 $\boldsymbol{x}^*$ 已知的前提下，要求在 $\boldsymbol{x}^*$ 的邻域 $S(\boldsymbol{x}^*, \delta)$ 上满足压缩条件，可得局部收敛性。

定义（局部收敛）

设 $\boldsymbol{x}^* = G(\boldsymbol{x}^*)$。若 $\boldsymbol{x}^*$ 的邻域 $S \subset D$，使得

$$\forall \boldsymbol{x}^{(0)} \in S,\ \boldsymbol{x}^{(k)} \in S,\ \boldsymbol{x}^{(k)} \to \boldsymbol{x}^*$$

称 $\boldsymbol{x}^*$ 是 S 的吸引点，S 为 $\boldsymbol{x}^*$ 的吸引域。若 $\boldsymbol{x}^*$ 有吸引域，则称其为局部收敛的。

推论

设 $G: D \subset \mathbb{R}^n \to \mathbb{R}^n$，$\boldsymbol{x}^* = G(\boldsymbol{x}^*)$。若有开球 $S = S(\boldsymbol{x}^*, \delta)$ 和常数 $\alpha \in (0,1)$，使得

$$\|G(\boldsymbol{x}) - G(\boldsymbol{x}^*)\| = \|G(\boldsymbol{x}) - \boldsymbol{x}^*\| \leq \alpha \|\boldsymbol{x} - \boldsymbol{x}^*\|, \ \forall \boldsymbol{x} \in S,$$

则 $\forall \boldsymbol{x}^{(0)} \in S$，$\boldsymbol{x}^*$ 是迭代序列 $\boldsymbol{x}^{(k)}$ 的吸引点（收敛极限）。

在实际应用的时候用 $G(\boldsymbol{x})$ 在 $\boldsymbol{x}^*$ 点的导数 $G'(\boldsymbol{x}^*)$ 比压缩条件更方便。

命题

设 $G: D \subset \mathbb{R}^n \to \mathbb{R}^n$ 在 $\boldsymbol{x}^* = G(\boldsymbol{x}^*)$ 处可导，若 $\rho(G'(\boldsymbol{x}^*)) = \sigma < 1$，则存在开球 $S = S(\boldsymbol{x}^*, \delta) \subset D$ 使得 $\forall \boldsymbol{x}^{(0)} \in S$，由不动点迭代产生的迭代序列收敛到 $\boldsymbol{x}^*$。

例

求解方程组

$$\begin{cases} x_1^2 - 10x_1 + x_2^2 + 8 = 0, \\ x_1 x_2^2 + x_1 - 10x_2 + 8 = 0. \end{cases}$$

数学家简介 (Galois)

埃瓦里斯特 • 伽罗瓦，*1811*年*10*月*25*日生，法国数学家。现代数学中的分支学科群论的创立者。用群论彻底解决了根式求解代数方程的问题， 而且由此发展了一整套关于群和域的理论，人们称之为伽罗瓦群和伽罗瓦理论。 在世时在数学上研究成果的重要意义没被人们所认识，曾呈送科学院*3*篇学术论文，均被退回或遗失。后转向政治，支持共和党，曾两次被捕。*21*岁时死于一次决斗。 他系统化地阐释了为何五次以上之方程式没有公式解，而四次以下有公式解。 他漂亮地证明高斯的论断：若用尺规作图能作出正p边形，p 为质数的充要条件为 $p = 2^{2^k} + 1$ 。（所以正十七边形可做图）。 他解决了古代三大作图问题中的两个：“不能任意三等分角”，“倍立方不可能”。



Newton迭代

求解 $F(\boldsymbol{x}) = 0.$

因为

$$F(\boldsymbol{x}) \approx F(\boldsymbol{x}^{(k)}) + F'(\boldsymbol{x}^{(k)})(\boldsymbol{x} - \boldsymbol{x}^{(k)}),$$

得不动点迭代格式

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - F'(\boldsymbol{x}^{(k)})^{-1} F(\boldsymbol{x}^{(k)})$$

称为Newton迭代法。

Newton迭代法

具体的计算步骤

1. 给定初值 $\boldsymbol{x}^{(0)}$，计算 $F'(\boldsymbol{x}^{(0)})$；
2. 对 $k = 1, 2, \cdots$，求解线性方程组

$$F'(\boldsymbol{x}^{(k)})\Delta\boldsymbol{x}^{(k)} = -F(\boldsymbol{x}^{(k)}), \quad \text{牛顿方程},$$

   得到 $\Delta\boldsymbol{x}^{(k)}$；
3. 更新

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \Delta\boldsymbol{x}^{(k)},$$

   计算 $F'(\boldsymbol{x}^{(k+1)})$，返回第2步。

用Newton 迭代法求解非线性方程组

$$F(\boldsymbol{x}) = \begin{bmatrix} x_1^2 - 10x_1 + x_2^2 + 8 \\ x_1 x_2^2 + x_1 - 10x_2 + 8 \end{bmatrix} = \boldsymbol{0}.$$

则其Jacobi矩阵为

$$F'(\boldsymbol{x}) = \begin{bmatrix} 2x_1 - 10 & 2x_2 \\ x_2^2 + 1 & 2x_1 x_2 - 10 \end{bmatrix}.$$

选取初值 $\boldsymbol{x}^{(0)} = (0,0)^{\mathsf{T}}$，求解方程组

$$F'(\boldsymbol{x}^{(0)})\Delta\boldsymbol{x}^{(0)} = -F(\boldsymbol{x}^{(0)}) \Longleftrightarrow \begin{bmatrix} -10 & 0 \\ 1 & -10 \end{bmatrix} \Delta\boldsymbol{x}^{(0)} = \begin{bmatrix} -8 \\ -8 \end{bmatrix}$$

得 $\Delta\boldsymbol{x}^{(0)} = (0.8, 0.88)^{\mathsf{T}} \Rightarrow \boldsymbol{x}^{(1)} = \boldsymbol{x}^{(0)} + \Delta\boldsymbol{x}^{(0)} = (0.8, 0.88)^{\mathsf{T}}$。继续计算有 $\boldsymbol{x}^{(2)} = (0.991787, 0.991812)^{\mathsf{T}}$，$\boldsymbol{x}^{(3)} = (0.999975, 0.999969)^{\mathsf{T}}$，$\boldsymbol{x}^{(4)} = (1.000000, 1.000000)^{\mathsf{T}}$。

定理（Newton 迭代的收敛性）

设 $F: D \subset \mathbb{R}^n \to \mathbb{R}^n$，$F(\boldsymbol{x}^*) = \mathbf{0}$，$F(\boldsymbol{x})$ 在 $\boldsymbol{x}^*$ 的开邻域 $S_0 \subset D$ 上可导，且 $F'(\boldsymbol{x})$ 连续，$F'(\boldsymbol{x}^*)$ 非奇异，则存在闭球 $S = S(\boldsymbol{x}^*, \delta) \subset S_0$，使映射

$$G(\boldsymbol{x}) = \boldsymbol{x} - F'(\boldsymbol{x})^{-1} F(\boldsymbol{x}),$$

对所有 $\boldsymbol{x} \in S$ 有意义，且牛顿法生成的序列超线性收敛于 $\boldsymbol{x}^*$。若

$$\|F'(\boldsymbol{x}) - F'(\boldsymbol{x}^*)\| \le L\|\boldsymbol{x} - \boldsymbol{x}^*\|, \ \forall \boldsymbol{x} \in S.$$

则迭代序列 $\{\boldsymbol{x}^{(k)}\}_{k=0}^{\infty}$ 至少平方收敛。

牛顿法的优缺点

- 收敛快；
- 局部收敛性，计算量大，每步要计算 $F(\boldsymbol{x})$ 及 $F'(\boldsymbol{x})$ 的值，并解线性方程组。

实际计算的时候，首先必须估计 $F(\boldsymbol{x}^{(k)})$ 以决定算法是否终止。如果要继续迭代，则要计算Jacobi矩阵 $F'(\boldsymbol{x}^{(k)})$，接着对 $F'(\boldsymbol{x})$ 做分解，计算

$$F'(\boldsymbol{x}^{(k)})\boldsymbol{s} = -F(\boldsymbol{x}^{(k)}) \Rightarrow \boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \boldsymbol{s}.$$

计算 $F'(\boldsymbol{x}^{(k)})$ 和对它作分解的计算量最大。如果 $F'(\boldsymbol{x}^{(k)})$ 是稠密阵，那么 作分解的计算量为 $O(n^3)$。而用数值微商近似 $F'(\boldsymbol{x}^{(k)})$ 的计算量为计算 $F(\boldsymbol{x}^{(k)})$ 的计算量 的 n 倍；则当 n 很大时计算量很大。如果 $F'(\boldsymbol{x}^{(k)})$ 是稀疏的，则计算量可以大大减少。

Newton迭代算法

Newton迭代法

1. $r_0 = \|F(\boldsymbol{x})\|$,
2. do while $\|F(\boldsymbol{x})\| > \tau_r r_0 + \tau_a$;
   (a) 计算 $F'(\boldsymbol{x})$;
   (b) 分解 $F'(\boldsymbol{x}) = LU$;
   (c) 求解 $LU\Delta\boldsymbol{x} = -F(\boldsymbol{x})$;
   (d) 更新 $\boldsymbol{x} = \boldsymbol{x} + \Delta\boldsymbol{x}$;
   (e) 估计分析 $F(\boldsymbol{x})$。

Newton法的变形

原始的Newton法由于每一步都需要计算 $F'(\boldsymbol{x})\boldsymbol{s} = -F(\boldsymbol{x})$，计算量很大，为了减少计算量，必须对 Newton法进行修改。 最简单的方法用 $F'(\boldsymbol{x}^{(0)})$ 代替所有的 $F'(\boldsymbol{x}^{(k)})$，这样就得到简化牛顿法（chord 方法）：

1. $r_0 = \|F(\boldsymbol{x})\|$;
2. 计算 $F'(\boldsymbol{x})$;
3. 分解 $F'(\boldsymbol{x}) = LU$;
4. do while $\|F(\boldsymbol{x})\| > \tau_r r_0 + \tau_a$;
   (a) 求解 $LU\Delta\boldsymbol{x} = -F(\boldsymbol{x})$;
   (b) $\boldsymbol{x} = \boldsymbol{x} + \Delta\boldsymbol{x}$;
   (c) 估计分析 $F(\boldsymbol{x})$。

虽然chord方法计算量小但是只有线性收敛，为了结合chord法计算量少和Newton法收敛快的优点可以设计修正牛顿法(Shamanskii方法)：

$$\begin{cases} \boldsymbol{x}^{(k,i+1)} = \boldsymbol{x}^{(k,i)} - F'(\boldsymbol{x}^{(k)})^{-1} F(\boldsymbol{x}^{(k,i)}), \ i = 0, 1, \cdots, m-1, \\ \boldsymbol{x}^{(k)} = \boldsymbol{x}^{(k,0)}, \boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k,m)}, \ k = 0, 1, \cdots \end{cases}$$

注记

当 $m = 1$ 时就是Newton法，$m = \infty$ 时为chord方法。

定理（Shamanskii方法的收敛性）

设 $F(\boldsymbol{x}) = \boldsymbol{0}$ 有唯一解 $\boldsymbol{x}^*$，$F'(\boldsymbol{x})$ 在区域 D 上Lipschitz连续且 $F'(\boldsymbol{x}^*)$ 非奇异，则存在 $K_S > 0, \delta > 0$ 使得若 $\boldsymbol{x}^{(0)} \in S = S(\boldsymbol{x}^*, \delta)$，则Shamanskii方法超线性收敛到 $\boldsymbol{x}^*$，收敛阶为 $m+1$ 且

$$\|\boldsymbol{e}_{k+1}\| \leq K_S \|\boldsymbol{e}_k\|^{m+1}, m \geq 1.$$

阻尼Newton法

在使用Newton法求解的时候要求 $F'(\boldsymbol{x}^{(k)})$ 非奇异，所以当 $F'(\boldsymbol{x}^{(k)})$ 奇异或严重病态时迭代法无法进行下去。

阻尼 Newton 法

可在 Newton 法中引入参数 λ_k 将迭代序列改为

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \left[F'(\boldsymbol{x}^{(k)}) + \lambda_k I\right]^{-1} F(\boldsymbol{x}^{(k)}),\ k = 0, 1, \cdots$$

λ_k 称为阻尼参数，上面的方法称为阻尼Newton法。

适当选取 λ_k 可以使 $F'(\boldsymbol{x}^{(k)}) + \lambda_k I$ 非奇异，非病态，从而使迭代序列 $\{\boldsymbol{x}^{(k)}\}_0^{\infty}$ 有意义。

此时如果 $\boldsymbol{x}^{(k)} \to \boldsymbol{x}^*$，只有线性收敛速度。

牛顿法的缺陷

牛顿法适用于优化问题的高精度求解，但没有全局收敛性质。此在实际应用中通常会使用梯度类算法先求得较低精度的解，而后调用牛顿法来获得高精度的解。

但 Newton 法在求解优化问题时还有如下缺点：

1. 每一步迭代需要求解一个 n 维线性方程组，这导致在高维问题中计算量很大。海瑟矩阵 $\nabla^2 f(\boldsymbol{x}^{(k)})$ 既不容易计算又不容易储存。
2. 当 $\nabla^2 f(\boldsymbol{x})$ 不正定时，由牛顿方程给出的解 $\boldsymbol{d}^{(k)}$ 的性质通常比较差。 当海瑟矩阵正定时， $\boldsymbol{d}^{(k)}$ 是一个下降方向，而在其他情况下 $\boldsymbol{d}^{(k)}$ 不一定为下降方向。
3. 当迭代点距最优值较远时，直接选取步长 $\alpha_k = 1$ 会使得迭代极其不稳定，在有些情况下迭代点列会发散。

拟 Newton 法

克服以上缺点的一个办法是拟 Newton 法。

1. 对于大规模问题，$\nabla^2 f(\boldsymbol{x}^{(k)})$ 计算代价特别大或者难以得到，即便得矩阵还需求解一个大规模线性方程组。那么能否使用海瑟矩阵或其逆矩阵的近似来进行牛顿迭代呢？
2. 拟牛顿法便是这样的算法，它能够在每一步以较小的计算代价生成近似矩阵，并且使用近似矩阵代替海瑟矩阵而产生的迭代序列仍具有超线性收敛的性质。
3. 拟牛顿方法不计算海瑟矩阵 $\nabla^2 f(\boldsymbol{x}^{(k)})$，而是构造其近似矩阵 B_k 或其逆的近似矩阵 H_k。我们希望 B_k 或 H_k 仍然保留原矩阵的部分性质。那么拟牛顿矩阵应该满足一些什么性质？如何构造它们呢？

割线方程

设 $f(\boldsymbol{x})$ 二次连续可微，则其梯度 $\nabla f(\boldsymbol{x}) = F(\boldsymbol{x})$ 在 $\boldsymbol{x}^{(k+1)}$ 处的近似为

$$\nabla f(\boldsymbol{x}) = \nabla f(\boldsymbol{x}^{(k+1)}) + \nabla^2 f(\boldsymbol{x}^{(k+1)})(\boldsymbol{x} - \boldsymbol{x}^{(k+1)}) + \mathcal{O}(\|\boldsymbol{x} - \boldsymbol{x}^{(k+1)}\|^2).$$

令 $\boldsymbol{x} = \boldsymbol{x}^{(k)}, \boldsymbol{s}^k = \boldsymbol{x}^{(k+1)} - \boldsymbol{x}^{(k)}$ 以及 $\boldsymbol{y}^k = \nabla f(\boldsymbol{x}^{(k+1)}) - \nabla f(\boldsymbol{x}^{(k)})$，可得

$$\nabla^2 f(\boldsymbol{x}^{(k+1)})\boldsymbol{s}^k + \mathcal{O}(\|\boldsymbol{s}^{(k)}\|^2) = \boldsymbol{y}^k.$$

忽略高阶项 $\|\boldsymbol{s}^k\|^2$，希望近似矩阵 B_{k+1} 满足方程

$$\boldsymbol{y}^k = B_{k+1}\boldsymbol{s}^k,$$

或者其逆的近似矩阵 H_{k+1} 满足方程

$$\boldsymbol{s}^k = H_{k+1}\boldsymbol{y}^k.$$

上述两个方程称为割线方程。

曲率条件

在求解优化问题时，近似矩阵 B_k 的正定性是个很关键的因素。

在割线方程的两边同时左乘 $(\boldsymbol{s}^k)^\top$ 可得

$$(\boldsymbol{s}^k)^\top B_{k+1}\boldsymbol{s}^k = (\boldsymbol{s}^k)^\top \boldsymbol{y}^k,$$

因此条件

$$(\boldsymbol{s}^k)^\top \boldsymbol{y}^k > 0,$$

为 B_{k+1} 正定的一个必要条件。很多时候额外要求这个条件在迭代过程中始终满足，这个条件也称为曲率条件。

近似矩阵 B_{k+1} 或 H_{k+1} 是由上一步迭代矩阵 B_k 或 H_k 分别加上一个修正得到，并且要求满足割线方程。

算法（拟牛顿法算法框架）

1. 给定 $\boldsymbol{x}^{(0)} \in \mathbb{R}^n$，初始矩阵 $B_0 \in \mathbb{R}^{n\times n}$（或 H_0），令 $k = 0$.
2. **while** 未达到停机准则 **do**
3. 计算方向 $\boldsymbol{d}^{(k)} = -B_k^{-1} F(\boldsymbol{x}^{(k)})$ 或 $\boldsymbol{d}^{(k)} = -H_k F(\boldsymbol{x}^{(k)})$.
4. 通过线搜索找到合适的步长 $\alpha_k > 0$，令 $\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{d}^{(k)}$.
5. 更新近似矩阵 B_{k+1} 或其逆矩阵的近似 H_{k+1}.
6. $k \leftarrow k + 1$.
7. **end while**

在实际应用中基于 H_k 的拟牛顿法更加实用，这是因为根据 H_k 计算下降方向 $\boldsymbol{d}^{(k)}$ 不需要求解线性方程组，而求解线性方程组在大规模问题上是非常耗时的。但基于 B_k 的拟牛顿法有比较好的理论性质，产生的迭代序列比较稳定。如果有办法快速求解线性方程组，也可采用基于 B_k 的拟牛顿法。

秩一更新公式

秩一更新（SR1）公式是结构最简单的拟牛顿矩阵更新公式。设 B_k 是第 k 步的近似矩阵，希望通过对 B_k 进行秩一修正得到 B_{k+1} 使其满足割线方程。设

$$B_{k+1} = B_k + \boldsymbol{u_k v_k}^{\mathsf{T}}, \quad \boldsymbol{u}_k, \boldsymbol{v}_k \text{未知}.$$

其满足割线方程

$$B_{k+1}\boldsymbol{s}^k = \boldsymbol{y}^k \Longrightarrow (B_k + \boldsymbol{u}_k\boldsymbol{v}_k^{\mathsf{T}})\boldsymbol{s}^k = \boldsymbol{y}^k,$$

亦即

$$\boldsymbol{u}_k\boldsymbol{v}_k^{\mathsf{T}}\boldsymbol{s}^k = \boldsymbol{y}^k - B_k\boldsymbol{s}^k$$

因为 $\boldsymbol{v}_k^{\mathsf{T}}\boldsymbol{s}^k \in \mathbb{R}$，因此 $\boldsymbol{u}_k$ 与 $\boldsymbol{y}^k - B_k\boldsymbol{s}^k$ 方向相同，可得

$$\boldsymbol{u}_k = (\boldsymbol{y}^k - B_k\boldsymbol{s}^k)/\boldsymbol{v}_k^{\mathsf{T}}\boldsymbol{s}^k,$$

$$\Longrightarrow \quad B_{k+1} = B_k + (\boldsymbol{y}^k - B_k\boldsymbol{s}^k)\frac{\boldsymbol{v}_k^{\mathsf{T}}}{\boldsymbol{v}_k^{\mathsf{T}}\boldsymbol{s}^k}.$$

Broyden方法

- 若取 $\boldsymbol{v}_k = \boldsymbol{s}^k$，得Broyden秩1方法

$$\begin{cases} \boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - B_k^{-1} F(\boldsymbol{x}^{(k)}), \quad k = 0, 1, \cdots \\ B_{k+1} = B_k + \dfrac{(\boldsymbol{y}^k - B_k \boldsymbol{s}^k)(\boldsymbol{s}^k)^{\mathsf{T}}}{(\boldsymbol{s}^k)^{\mathsf{T}} \boldsymbol{s}^k}. \end{cases}$$

- 若取 $\boldsymbol{v}_k = F(\boldsymbol{x}^{(k+1)})$，则

$$\begin{cases} \boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - B_k^{-1} F(\boldsymbol{x}^{(k)}), \quad k = 0, 1, \cdots \\ B_{k+1} = B_k + \dfrac{(\boldsymbol{y}^k - B_k \boldsymbol{s}^k)(\boldsymbol{y}^k - B_k \boldsymbol{s}^k)^{\mathsf{T}}}{(\boldsymbol{y}^k - B_k \boldsymbol{s}^k)^{\mathsf{T}} \boldsymbol{s}^k}. \end{cases}$$

  称为Broyden对称秩1方法。

- 秩一方法结构简单，但是不能保证矩阵在迭代过程中保持正定。

定理（Sherman-Morrison 公式）

设 $A \in \mathbb{R}^{n\times n}$ 非奇异，$\boldsymbol{u},\boldsymbol{v} \in \mathbb{R}^n$，当且仅当 $1+\boldsymbol{v}^{\mathsf{T}}A^{-1}\boldsymbol{u} \neq 0$ 时，$A+\boldsymbol{u}\boldsymbol{v}^{\mathsf{T}}$ 可逆，且有

$$(A+\boldsymbol{u}\boldsymbol{v}^{\mathsf{T}})^{-1} = \left(I - \frac{A^{-1}\boldsymbol{u}\boldsymbol{v}^{\mathsf{T}}}{1+\boldsymbol{v}^{\mathsf{T}}A^{-1}\boldsymbol{u}}\right)A^{-1}.$$

逆Broyden方法

可以避免求逆得

- 逆Broyden秩1方法

$$\begin{cases} \boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - H_k F(\boldsymbol{x}^{(k)}), \quad k = 0, 1, \cdots \\ H_{k+1} = H_k + \dfrac{(\boldsymbol{s}^k - H_k \boldsymbol{y}^k)(\boldsymbol{s}^k)^{\mathsf{T}} H_k}{(\boldsymbol{s}^k)^{\mathsf{T}} H_k \boldsymbol{y}^k}. \end{cases}$$

- 逆Broyden对称秩1方法

$$\begin{cases} \boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - H_k F(\boldsymbol{x}^{(k)}), \quad k = 0, 1, \cdots \\ H_{k+1} = H_k + \dfrac{(\boldsymbol{s}^k - H_k \boldsymbol{y}^k)(\boldsymbol{s}^k - H_k \boldsymbol{y}^k)^{\mathsf{T}}}{(\boldsymbol{s}^k - H_k \boldsymbol{y}^k)^{\mathsf{T}} \boldsymbol{y}^k}. \end{cases}$$

C. T. Kelley, Iterative Methods for Linear and Nonlinear Equations,Society for Industrial and Applied Mathematics(SIAM), Philadelphia 1995.

BFGS公式

为克服秩一方法的缺陷，可以考虑 B_k 的秩二更新，类似设

$$B_{k+1} = B_k + auu^{\mathsf{T}} + bvv^{\mathsf{T}},\quad u, v \in \mathbb{R}^n, a, b \in \mathbb{R}待定.$$

根据割线方程有

$$B_{k+1}s^k = (B_k + auu^{\mathsf{T}} + bvv^{\mathsf{T}})s^k = y^k,$$

整理可得

$$(a \cdot u^{\mathsf{T}}s^k)u + (b \cdot v^{\mathsf{T}}s^k)v = y^k - B_k s^k$$

通过选取适当的 u 和 v 使得上式成立即可。一种最直接的取法就是让上面等式左右两边的两项分别对应相等，即

$$\begin{aligned} u &= y^k, & a \cdot u^{\mathsf{T}}s^k &= 1, \\ v &= B_k s^k, & b \cdot v^{\mathsf{T}}s^k &= -1. \end{aligned}$$

BFGS公式

- 得到 BFGS 公式

$$B_{k+1} = B_k + \frac{\boldsymbol{y}^k(\boldsymbol{y}^k)^\mathsf{T}}{(\boldsymbol{s}^k)^\mathsf{T}\boldsymbol{y}^k} - \frac{B_k\boldsymbol{s}^k(B_k\boldsymbol{s}^k)^\mathsf{T}}{(\boldsymbol{s}^k)^\mathsf{T}B_k\boldsymbol{s}^k}.$$

这就是基于 B_k 的 BFGS 公式，是由 Broyden, Fletcher, Goldfarb, Shanno 四人名字的首字母组成。

- 令 $H_k = B_k^{-1}$，可得基于 H_k 的 BFGS 公式：

$$H_{k+1} = (I - \rho_k\boldsymbol{s}^k(\boldsymbol{y}^k)^\mathsf{T})^\mathsf{T}H_k(I - \rho_k\boldsymbol{s}^k(\boldsymbol{y}^k)^\mathsf{T}) + \rho_k\boldsymbol{s}^k(\boldsymbol{s}^k)^\mathsf{T},$$

其中

$$\rho_k = \frac{1}{(\boldsymbol{s}^k)^\mathsf{T}\boldsymbol{y}^k}.$$

若要 BFGS 公式更新产生的矩阵 H_{k+1} 正定，一个充分条件是：

$$(s^k)^T y^k > 0, \quad \text{且 } H_k \text{ 正定.}$$

BFGS 公式是目前最有效的拟牛顿更新格式之一，它有比较好的理论性质，实现起来也并不复杂。

BFGS 定义的 H_{k+1} 是如下优化问题的解：

$$\begin{aligned} \min_{H} \quad & \|H - H_k\|_W \\ s.t \quad & H = H^{\mathsf{T}} \\ & Hy^k = s^k \end{aligned}$$

这个优化问题的含义是在满足割线方程的对称矩阵中找到离 H_k 最近的矩阵 H。此处 $\|\cdot\|_W$ 是如下定义的加权范数：

$$\|H\|_W = \|W^{1/2} H W^{1/2}\|, \quad Ws^k = y^k.$$

BFGS

